

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÁO CÁO PROJECT III
PHÁT HIỆN TẦN CÔNG MẠNG DỰA TRÊN CÁC
PHƯƠNG PHÁP HỌC MÁY

Sinh viên thực hiện: **Nguyễn Thị Tú Quyên**
MSSV: 20225223
Tên học phần: Project III
Mã học phần: IT3943
Mã lớp: 755578
Giảng viên hướng dẫn: **TS. Nguyễn Hồng Quang**

Hà Nội, tháng 1 năm 2026

Mục lục

1	Mở đầu	1
1.1	Đặt vấn đề	1
1.2	Bộ dữ liệu NSL-KDD	1
1.2.1	Chi tiết các đặc trưng	2
1.2.2	Chi tiết các nhóm tấn công và kịch bản xâm nhập	3
1.2.3	Phân bố mẫu tấn công trong bộ dữ liệu NSL-KDD	4
1.3	Mục tiêu nghiên cứu	5
1.4	Bố cục đề án	5
2	Cơ sở lý thuyết	6
2.1	Federated Learning	6
2.1.1	Bối cảnh ra đời	6
2.1.2	Federated Learning framework	7
2.1.3	Thuật toán tổng hợp tham số	8
2.1.4	Ưu điểm của phương pháp	8
2.2	Học sâu và Mạng nơ-ron tích chập	8
2.2.1	Tổng quan về Học sâu (Deep Learning)	8
2.2.2	Mạng nơ-ron tích chập (Convolutional Neural Networks - CNN)	9
2.3	Few-shot Learning	9
2.3.1	Bối cảnh và Động lực	9
2.3.2	Định nghĩa bài toán N-way K-shot	10
2.3.3	Cơ chế Episode-based Training	10
2.3.4	Phân loại Few-shot Learning	11
3	Phương pháp và kỹ thuật đề xuất	13
3.1	Tổng quan mô hình đề xuất	13
3.1.1	Kiến trúc hệ thống	13
3.2	Thuật toán IGTD	13
3.2.1	Khung lý thuyết và Xây dựng ma trận xếp hạng	13
3.2.2	Tối ưu hóa hàm mục tiêu - Objective Function	14
3.2.3	Quy trình thực thi thuật toán IGTD	14
3.3	Kiến trúc mạng nơ-ron tích chập khối DSC - CNN	15
3.3.1	Mạng nơ-ron tích chập tiêu chuẩn (Standard CNN)	15
3.3.2	Tích chập tách rời theo chiều sâu (Depthwise Separable Convolution - DSC)	15
3.3.3	So sánh Standard CNN và DSC-CNN	16
3.4	Chiến lược huấn luyện Lai (Hybrid Training)	16
3.4.1	Giai đoạn 1: Pre-training với Triplet Loss	16
3.4.2	Giai đoạn 2: Fine-tuning với Focal Loss	17
3.5	Lập luận lựa chọn phương pháp	17

3.5.1	Lý do lựa chọn Metric-based Few-shot Learning	17
3.5.2	Lý do lựa chọn IGTD kết hợp DSC-CNN	17
3.5.3	Lý do lựa chọn độ đo Metric-based: Khoảng cách Euclidean	18
4	Xây dựng mô hình và triển khai hệ thống	19
4.1	Môi trường cài đặt	19
4.2	Tiền xử lý dữ liệu	19
4.2.1	Ảnh xạ nhóm- nhãn tần công	19
4.2.2	Xử lý đặc trưng	20
4.2.3	Cơ chế IGTD	20
4.3	Xây dựng Kiến trúc mô hình	20
4.3.1	Khởi tích chập tách rời DSC Block	20
4.3.2	Kiến trúc mạng Backbone DSC_CNN	21
4.4	Chiến lược huấn luyện lại	21
4.4.1	Giai đoạn 1: Pre-training (Học đại diện	21
4.4.2	Giai đoạn 2: Few-shot Learning với Prototypical Networks	21
4.4.3	Tinh chỉnh Focal Loss	21
4.5	Kết quả và đánh giá	22
4.5.1	Bộ trích xuất đặc trưng	22
4.5.2	Chỉ số đánh giá mô hình	24
4.5.3	Kịch bản đánh giá	25
5	Tổng kết và Tiềm năng tích hợp Federated Learning	30
5.1	Tổng kết kết quả nghiên cứu	30
5.2	Hạn chế tồn tại	30
5.3	Tiềm năng tích hợp Federated Learning	31
5.3.1	Sự phù hợp của DSC-CNN với môi trường biên	31
5.3.2	Bảo mật quyền riêng tư dữ liệu	31
5.3.3	Kiến trúc đề xuất cho tương lai	31
5.4	Kết luận chung	32
	Tài liệu tham khảo	33

Chương 1

Mở đầu

1.1 Đặt vấn đề

Trong kỷ nguyên kết nối vạn vật (IoT) và dữ liệu lớn, an ninh mạng đã trở thành một trong những ưu tiên hàng đầu của mọi tổ chức. Hệ thống phát hiện xâm nhập mạng (NIDS) đóng vai trò then chốt trong việc giám sát và ngăn chặn các hành vi gây hại. Tuy nhiên, các hệ thống NIDS truyền thống thường gặp phải thách thức lớn:

1. **Quyền riêng tư và Bằng thông:** Việc tập trung một lượng lớn dữ liệu thô nhạy cảm từ các nút thiết bị về máy chủ trung tâm để huấn luyện mô hình gây ra rủi ro rò rỉ thông tin và tiêu tốn tài nguyên mạng đáng kể. **Học liên kết - Federated Learning** đã nổi lên như một hướng đi đầy triển vọng, khắc phục nhược điểm của các mô hình truyền thống trong môi trường dữ liệu phân tán. FL cho phép các mô hình học máy được huấn luyện cục bộ tại chỗ mà không cần chia sẻ dữ liệu gốc (raw data).
2. **Sự khan hiếm dữ liệu và Mất cân bằng dữ liệu:** Với sự phát triển của công nghệ, các hệ thống NIDS phải đối mặt với sự gia tăng của các loại tấn công mới (Zero-day) thường có số lượng mẫu cực kỳ ít. Do chỉ với rất ít mẫu, các mô hình truyền thống gặp khó khăn trong việc tổng quát hóa và nhận diện chính xác. **Học ít mẫu - Few-shot Learning** ra đời với mục tiêu giúp hệ thống nhận diện chỉ với một vài mẫu hỗ trợ.

1.2 Bộ dữ liệu NSL-KDD

Nghiên cứu này sử dụng bộ dữ liệu NSL-KDD. Mặc dù đã ra đời từ lâu, bộ dữ liệu NSL-KDD vẫn được coi là bộ dữ liệu chuẩn mực để đánh giá các thuật toán phát hiện xâm nhập mạng (NIDS). Đây là phiên bản khắc phục các hạn chế lớn của KDD Cup 99 bằng cách loại bỏ hơn 78% các bản ghi trùng lặp trong tập huấn luyện và 75% trong tập kiểm tra. Đây là bộ dữ liệu dạng bảng đã qua xử lý, mỗi bản ghi tương ứng với một kết nối mạng.

Bộ dữ liệu NSL-KDD được thiết kế với cấu trúc phân cấp nhằm đánh giá khả năng tổng quát hóa của các mô hình học máy thông qua ba tập dữ liệu chính:

- **Tập KDDTrain+:** Đây là tập dữ liệu chính dùng để huấn luyện mô hình, bao gồm đầy đủ các bản ghi đã loại bỏ trùng lặp. Tập này chứa 125.973 bản ghi, bao gồm dữ liệu bình thường (Normal) và 4 nhóm tấn công chính: DoS, Probe, R2L, và U2R. Tỷ lệ phân bố giữa các lớp giúp mô hình học được các đặc trưng cơ bản của các hành vi xâm nhập phổ biến.
- **Tập KDDTest+:** Đây là tập dữ liệu để kiểm tra hiệu năng cuối cùng của mô hình sau khi huấn luyện, bao gồm 22.544 bản ghi. Đặc điểm quan trọng của tập này là bao gồm các kiểu tấn

công mới không xuất hiện trong tập huấn luyện, thách thức khả năng nhận diện các mối đe dọa chưa biết của hệ thống.

- **Tập KDDTest-21:** Đây là một tập con của KDDTest+, bao gồm 11.850 bản ghi và được coi là tập thử thách nhất. Nó loại bỏ các bản ghi mà hầu hết các thuật toán học máy cơ bản có thể dễ dàng phân loại đúng (độ khó 21/21), giúp đánh giá chính xác năng lực phát hiện các cuộc tấn công tinh vi và hiếm gặp.

1.2.1 Chi tiết các đặc trưng

Mỗi bản ghi trong NSL-KDD bao gồm **41 đặc trưng** mô tả một kết nối mạng và **1 nhãn tấn công**. Các đặc trưng này được phân chia thành bốn nhóm chức năng chính:

1. **Đặc trưng cơ bản (Basic features):** Chứa các thông tin định danh và định lượng của một kết nối.

STT	Tên đặc trưng	Mô tả
1	duration	Thời gian kết nối (giây)
2	protocol_type	Giao thức (tcp, udp, icmp)
3	service	Dịch vụ mạng (http, telnet, smtp,...)
4	flag	Trạng thái kết nối (SF, SO, REJ,...)
5	src_bytes	Số byte từ nguồn đến đích
6	dst_bytes	Số byte từ đích đến nguồn
7	land	1 nếu cùng IP/Port nguồn và đích
8	wrong_fragment	Số lượng fragment sai
9	urgent	Số lượng gói tin khẩn cấp

Bảng 1.1: Danh sách các đặc trưng cơ bản (1-9)

Đây là nhóm các đặc trưng giúp nhận diện các cuộc tấn công dựa trên lưu lượng lớn như DoS.

2. **Đặc trưng nội dung (Content features):** Theo dõi các hành vi bên trong gói tin sau khi đăng nhập thành công.

STT	Tên đặc trưng	Mô tả
10	hot	Số lượng các chỉ số "hot"(truy cập thư mục,...)
11	num_failed_logins	Số lần đăng nhập thất bại
12	logged_in	1 nếu đã đăng nhập thành công
13	num_compromised	Số lượng các điều kiện "bị tổn thương"
14	root_shell	1 nếu đã chiếm được quyền root shell
15	su_attempted	1 nếu lệnh "su root" đã được thử
16	num_root	Số lượng các truy cập quyền root
17	num_file_creations	Số lượng file được tạo mới
18	num_shells	Số lượng các prompt của shell
19	num_access_files	Số lần thực hiện các thao tác trên file
20	num_outbound_cmds	Số lượng các lệnh gửi đi trong một phiên ftp
21	is_host_login	1 nếu đăng nhập là admin/root
22	is_guest_login	1 nếu đăng nhập là tài khoản khách (guest)

Bảng 1.2: Danh sách các đặc trưng nội dung (10-22)

Đây là nhóm đặc trưng sống còn để phát hiện các cuộc tấn công tinh vi như U2R và R2L.

3. **Đặc trưng lưu lượng theo thời gian (Time-based Traffic):** Sử dụng cửa sổ trượt 2 giây để thống kê.

STT	Tên đặc trưng	Mô tả
23	count	Số kết nối đến cùng một host trong 2 giây qua
24	srv_count	Số kết nối đến cùng một dịch vụ trong 2 giây qua
25	serror_rate	Tỷ lệ kết nối có lỗi "SYN"(trong 23)
26	srv_serror_rate	Tỷ lệ kết nối có lỗi "SYN"(trong 24)
27	rerror_rate	Tỷ lệ kết nối có lỗi "REJ"(trong 23)
28	srv_rerror_rate	Tỷ lệ kết nối có lỗi "REJ"(trong 24)
29	same_srv_rate	Tỷ lệ kết nối đến cùng một dịch vụ (trong 23)
30	diff_srv_rate	Tỷ lệ kết nối đến các dịch vụ khác nhau (trong 23)
31	srv_diff_host_rate	Tỷ lệ kết nối đến các host khác nhau (trong 24)

Bảng 1.3: Danh sách đặc trưng lưu lượng dựa trên thời gian (23-31)

Đây là nhóm các đặc trưng giúp phát hiện các hành vi quét cổng (Probe) hoặc tấn công dồn dập trong thời gian ngắn.

4. **Đặc trưng lưu lượng theo máy chủ (Host-based Traffic):**

STT	Tên đặc trưng	Mô tả
32	dst_host_count	Số kết nối đến cùng một máy đích
33	dst_host_srv_count	Số kết nối cùng máy đích, cùng dịch vụ
34	dst_host_same_srv_rate	Tỷ lệ các kết nối cùng dịch vụ
35	dst_host_diff_srv_rate	Tỷ lệ các kết nối khác dịch vụ
36	dst_host_same_src_port_rate	Tỷ lệ các kết nối trên cùng một cổng nguồn
37	dst_host_srv_diff_host_rate	Tỷ lệ các kết nối đến các host khác nhau
38	dst_host_serror_rate	Tỷ lệ lỗi SYN của máy đích
39	dst_host_srv_serror_rate	Tỷ lệ lỗi SYN của dịch vụ tại máy đích
40	dst_host_rerror_rate	Tỷ lệ lỗi REJ của máy đích
41	dst_host_srv_rerror_rate	Tỷ lệ lỗi REJ của dịch vụ tại máy đích

Bảng 1.4: Danh sách đặc trưng lưu lượng dựa trên máy chủ đích (32-41)

Đây là nhóm các đặc trưng giúp nhận diện các cuộc tấn công diễn ra chậm, kéo dài nhằm vượt qua cơ chế kiểm tra theo thời gian thực.

1.2.2 Chi tiết các nhóm tấn công và kịch bản xâm nhập

1. **DoS (Denial of Service):** Kẻ tấn công làm tràn ngập bộ nhớ hoặc tài nguyên mạng nhằm làm tê liệt dịch vụ (ví dụ: *Neptune* dùng SYN flood).
 - Đặc trưng quan trọng: src_bytes, count, srv_count tăng đột biến do lượng kết nối dồn dập.
2. **Probe (Dò quét):** Hành vi quét cổng hoặc dịch vụ để tìm kiếm lỗ hổng hệ thống (ví dụ: *Satan*, *Nmap*).
 - Đặc trưng quan trọng: dst_host_diff_srv_rate cao (quét nhiều dịch vụ khác nhau), duration thường rất thấp (ngắt kết nối ngay sau khi có phản hồi).

3. **R2L (Remote to Local):** Kẻ tấn công không có tài khoản nhưng cố gắng truy cập trái phép từ máy xa vào máy cục bộ (ví dụ: *guess_passwd* để bẻ khóa mật khẩu).
- Đặc trưng quan trọng: *num_failed_logins*, *is_guest_login*.
 - Thách thức: Hành vi rất giống người dùng bình thường, không tạo ra lưu lượng đột biến nên cực kỳ khó phát hiện bằng các phương pháp phân tích lưu lượng thô.
4. **U2R (User to Root):** Kẻ tấn công sử dụng một tài khoản thông thường để khai thác lỗ hổng, chiếm quyền quản trị tối cao (ví dụ: *buffer_overflow*).
- Đặc trưng quan trọng: *root_shell*, *su_attempted*.
 - Thách thức: Đây là nhóm nguy hiểm nhất và có số lượng mẫu ít nhất trong bộ dữ liệu, khiến mô hình rất dễ bỏ qua.

Nhóm chính	Các nhãn tấn công
DoS	<i>back</i> , <i>land</i> , <i>neptune</i> , <i>pod</i> , <i>smurf</i> , <i>teardrop</i> , <i>apache2</i> , <i>mailbomb</i> , <i>processtable</i> , <i>udpstorm</i>
Probe	<i>ipsweep</i> , <i>nmap</i> , <i>portsweep</i> , <i>satan</i> , <i>mscan</i> , <i>saint</i>
R2L	<i>ftp_write</i> , <i>guess_passwd</i> , <i>imap</i> , <i>multihop</i> , <i>phf</i> , <i>spy</i> , <i>warezclient</i> , <i>warezmaster</i> , <i>sendmail</i> , <i>named</i> , <i>snmpgetattack</i> , <i>snmpguess</i> , <i>xlock</i> , <i>xsnoop</i> , <i>worm</i>
U2R	<i>buffer_overflow</i> , <i>loadmodule</i> , <i>perl</i> , <i>rootkit</i> , <i>ps</i> , <i>sqlattack</i> , <i>xterm</i>
Normal	<i>normal</i>

Bảng 1.5: Danh sách ánh xạ 39 loại tấn công trong NSL-KDD
(*In nghiêng là các nhãn chỉ xuất hiện trong tập Test*)

1.2.3 Phân bố mẫu tấn công trong bộ dữ liệu NSL-KDD

Sự phân bố mẫu dữ liệu giữa các tập huấn luyện và kiểm tra thể hiện rõ thách thức về dữ liệu ít mẫu:

Lớp	Tập Train+	Tỷ lệ (%)	Tập Test+	Tỷ lệ (%)	Tập Test-21	Tỷ lệ (%)
Normal	67,343	53.46%	9,711	43.08%	2,152	18.16%
DoS	45,927	36.46%	7,458	33.08%	4,342	36.64%
Probe	11,656	9.25%	2,421	10.74%	2,402	20.27%
R2L	995	0.79%	2,754	12.22%	2,754	23.24%
U2R	52	0.04%	200	0.89%	200	1.69%
Tổng	125,973	100.0%	22,544	100.0%	11,850	100.0%

Bảng 1.6: Chi tiết phân bố mẫu tấn công trên các tập dữ liệu NSL-KDD

Nhận xét: Dữ liệu NSL-KDD cho thấy sự mất cân bằng cực kỳ nghiêm trọng. Tại tập Train+, lớp U2R chỉ có 52 mẫu (0.04%), điều này khiến các mô hình Deep Learning truyền thống gặp khó khăn trong việc tổng quát hóa. Đặc biệt, các cuộc tấn công nguy hiểm như U2R và R2L vốn có đặc trưng hành vi tinh vi, việc có quá ít mẫu khiến bài toán phát hiện xâm nhập trở nên phức tạp, đòi hỏi các tiếp cận mới như Học ít mẫu (Few-shot Learning)

1.3 Mục tiêu nghiên cứu

Phạm vi nghiên cứu: Bộ dữ liệu phát hiện xâm nhập tiêu chuẩn NSL-KDD, tập trung vào các lớp tấn công thiểu số.

Mục tiêu nghiên cứu: Đề tài này tập trung nghiên cứu và xây dựng một hệ thống phát hiện xâm nhập lai ghép, kết hợp sức mạnh của thị giác máy tính và học máy phân tán nhằm:

1. **Ảnh hóa dữ liệu mạng:** Ứng dụng thuật toán IGTD để chuyển đổi các đặc trưng của bộ dữ liệu NSL-KDD thành các đại diện hình ảnh có tính nhỏ gọn và bảo tồn cấu trúc lân cận. Khắc phục hạn chế của dữ liệu dạng bảng thường khó thể hiện được mối quan hệ không gian phức tạp như dữ liệu hình ảnh.
2. **Cải thiện hiệu suất nhận diện ít mẫu:** Phát triển mô hình Few-shot Learning với thiết kế mô hình CNN nhẹ (DSC-CNN) kết hợp Metric Learning nhằm nâng cao khả năng phát hiện các cuộc tấn công hiếm gặp.
3. **Đảm bảo tính bảo mật và khả năng mở rộng:** Khả năng tích hợp mô hình vào khung Federated Learning để cho phép huấn luyện phân tán, bảo vệ quyền riêng tư người dùng.

1.4 Bố cục đồ án

Báo cáo được trình bày theo cấu trúc sau:

- Chương 1. Mở đầu: Giới thiệu bối cảnh, tính cấp thiết, bộ dữ liệu sử dụng và mục tiêu của đề tài.
- Chương 2. Cơ sở lý thuyết: Trình bày nền tảng về Federated Learning, Few-shot Learning và kiến trúc DSC-CNN.
- Chương 3. Các phương pháp và kỹ thuật đề xuất
- Chương 4. Xây dựng mô hình và Thực nghiệm:
- Chương 5. Tổng kết và Tiềm năng tích hợp Federated Learning

Chương 2

Cơ sở lý thuyết

Việc xác định được thách thức về mất cân bằng dữ liệu và sự phức tạp của đặc trưng mạng đặt ra yêu cầu phải có những phương pháp học máy tiên tiến hơn. Để giải quyết vấn đề này, đồ án sẽ dựa trên nền tảng của các kỹ thuật Deep Learning và Few-shot Learning. Chương 2 dưới đây sẽ trình bày cơ sở lý thuyết về các công nghệ cốt lõi này, làm tiền đề cho việc xây dựng mô hình đề xuất.

2.1 Federated Learning

2.1.1 Bối cảnh ra đời

Trong kỷ nguyên số, dữ liệu được ví như "dầu mỏ" của các hệ thống trí tuệ nhân tạo. Tuy nhiên, việc khai thác nguồn tài nguyên này đang đối mặt với những rào cản lớn:

- **Quyền riêng tư dữ liệu:** Các chính sách bảo mật nghiêm ngặt khiến việc tập trung dữ liệu nhạy cảm về một máy chủ duy nhất trở nên khả thi về mặt kỹ thuật nhưng vi phạm về mặt pháp lý.
- **Đảo dữ liệu (Data Silos):** Dữ liệu bị phân tán ở nhiều tổ chức khác nhau và không thể chia sẻ do lợi ích kinh tế hoặc rủi ro bảo mật.
- **Chi phí truyền tải:** Với sự bùng nổ của thiết bị IoT, việc gửi hàng Terabyte dữ liệu thô lên Cloud gây áp lực cực lớn cho băng thông mạng.

Federated Learning (FL) là một framework học máy phân tán được đề xuất bởi Google vào năm 2016 như một hướng đi mới. Thay vì tập trung hóa dữ liệu, FL thực hiện huấn luyện mô hình một cách phân tán, đảm bảo nguyên tắc: *"Dữ liệu ở lại tại chỗ, chỉ có tri thức được chia sẻ"*.

Hiện nay, các hệ thống phát hiện tấn công mạng sử dụng các mô hình học máy truyền thống (Centralized) đang đối mặt với hai thách thức chính mà Federated Learning có thể giải quyết:


- **An ninh dữ liệu:** Dữ liệu lưu lượng mạng thường chứa thông tin nhạy cảm. Việc chia sẻ dữ liệu này cho bên thứ ba gây ra rủi ro bảo mật lớn.
- **Sự phân tán dữ liệu:** Dữ liệu tấn công thường nằm rải rác ở các phòng ban khác nhau, một tổ chức đơn lẻ thường không có đủ mẫu dữ liệu để xây dựng mô hình chính xác.

2.1.2 Federated Learning framework

Kiến trúc mô hình Federated Learning cơ bản bao gồm hai thành phần chính:

- **Aggregation Server (Máy chủ tổng hợp):** Đóng vai trò là máy chủ trung tâm, chịu trách nhiệm khởi tạo mô hình toàn cục, điều phối quá trình huấn luyện và thực hiện thuật toán tổng hợp các tham số nhận được từ các thiết bị tham gia.
- **Clients (Các nút cục bộ):** Là các thực thể sở hữu dữ liệu riêng biệt (ví dụ: các phòng ban hoặc tổ chức khác nhau). Các Client thực hiện huấn luyện mô hình trên tập dữ liệu tại chỗ và chỉ gửi kết quả cập nhật mô hình về máy chủ trung tâm nhằm bảo mật thông tin nhạy cảm.

Quy trình huấn luyện Federated Learning diễn ra theo các bước lặp lại (rounds) như sau:



Hình 1: Quy trình hoạt động của Federated Learning

1. **Khởi tạo (Initialization):** Máy chủ trung tâm thiết lập mô hình ban đầu với các tham số nền tảng W_0
2. **Gửi tham số (Model Broadcast):** Máy chủ trung tâm gửi các tham số đến tất cả các bên tham gia (Clients) để làm cơ sở huấn luyện.
3. **Huấn luyện cục bộ (Local Training):** Mỗi nút sử dụng dữ liệu riêng của mình để huấn luyện mô hình. Quá trình này hoàn toàn diễn ra cục bộ, đảm bảo dữ liệu thô không bao giờ rời khỏi thiết bị, giúp ngăn chặn rò rỉ quyền riêng tư (Privacy Leakage).
4. **Thu thập tham số (Collect Parameters):** Sau khi hoàn tất huấn luyện cục bộ, các nút không gửi dữ liệu thô mà chỉ gửi các cập nhật tham số (như trọng số mô hình W_i hoặc gradient) về máy chủ trung tâm thông qua kênh truyền an toàn.
5. **Tổng hợp tham số (Model Aggregation):** Máy chủ trung tâm sử dụng thuật toán tổng hợp (ví dụ: Federated Averaging) để kết hợp các tham số từ tất cả các nút thành một mô hình chung W_{global} .
6. **Cập nhật mô hình toàn cục (Updated Global Model):** Máy chủ trung tâm cập nhật lại mô hình chung.

Quá trình này được lặp lại qua nhiều vòng cho đến khi mô hình đạt độ hội tụ và độ chính xác mong muốn.

2.1.3 Thuật toán tổng hợp tham số

Tính toán trọng số cho mô hình toàn cục dựa trên đóng góp dữ liệu của mỗi bên. Công thức tổng quát thường được sử dụng là:

$$W_{global} = \sum_{i=1}^n \frac{d_i}{D} W_i \quad (2.1)$$

Trong đó:

- W_i : Trọng số mô hình từ nút thứ i .
- d_i : Lượng dữ liệu tại nút i .
- $D = \sum_{i=1}^n d_i$: Tổng lượng dữ liệu của tất cả các nút tham gia.

2.1.4 Ưu điểm của phương pháp

Dựa trên kết quả thực nghiệm, phương pháp Federated Learning mang lại các lợi ích:

- **Bảo mật tối đa:** Chỉ các tham số mô hình được chia sẻ, giúp bảo vệ quyền riêng tư của từng đơn vị.
- **Tính cộng tác:** Cho phép các phòng ban khác nhau (cross-department) cùng xây dựng một mô hình phát hiện tấn công mạnh mẽ mà không cần tin tưởng hoàn toàn lẫn nhau về mặt dữ liệu.
- **Hiệu năng:** Đạt được độ chính xác và độ bền vững tương đương với các phương pháp huấn luyện tập trung truyền thống.

Như vậy, Federated Learning là xu hướng tất yếu trong việc xây dựng các hệ thống trí tuệ nhân tạo an toàn và phi tập trung trong tương lai.

2.2 Học sâu và Mạng nơ-ron tích chập

2.2.1 Tổng quan về Học sâu (Deep Learning)

Học sâu là một nhánh của Học máy (Machine Learning) dựa trên tập hợp các thuật toán nhằm mô phỏng các khái niệm trừu tượng cấp cao của dữ liệu bằng cách sử dụng nhiều lớp xử lý với các cấu trúc phức tạp. Khác với các thuật toán học máy truyền thống cần sự can thiệp của con người để trích xuất đặc trưng (Feature Engineering), các mô hình học sâu có khả năng tự động học các biểu diễn đặc trưng từ dữ liệu thô.

Kiến trúc cơ bản nhất của học sâu là Mạng nơ-ron nhân tạo (Artificial Neural Network - ANN), được lấy cảm hứng từ mạng lưới nơ-ron sinh học. Một mạng nơ-ron bao gồm ba thành phần chính: lớp đầu vào (Input layer), các lớp ẩn (Hidden layers) và lớp đầu ra (Output layer). Qua quá trình huấn luyện, mạng điều chỉnh các trọng số liên kết để tối thiểu hóa hàm mất mát, từ đó đưa ra dự đoán chính xác.

2.2.2 Mạng nơ-ron tích chập (Convolutional Neural Networks - CNN)

Trong khi ANN xử lý tốt dữ liệu dạng vector, Mạng nơ-ron tích chập (CNN) là kiến trúc chuyên biệt và hiệu quả nhất để xử lý dữ liệu dạng lưới, đặc biệt là hình ảnh. CNN hoạt động dựa trên ba cơ chế cốt lõi:

1. **Lớp Tích chập (Convolutional Layer):** Đây là thành phần quan trọng nhất của CNN. Thay vì kết nối toàn bộ các nơ-ron như ANN, lớp tích chập sử dụng các bộ lọc (filters/kernels) trượt qua toàn bộ hình ảnh đầu vào.
 - Mỗi bộ lọc thực hiện phép nhân chập với vùng dữ liệu cục bộ (Receptive field) để tạo ra bản đồ đặc trưng (Feature Map).
 - **Ý nghĩa:** Giúp mô hình phát hiện các đặc trưng cục bộ như cạnh, góc, đường cong ở các lớp đầu và các hình dạng phức tạp hơn ở các lớp sâu.
2. **Hàm kích hoạt phi tuyến (Non-linearity/ReLU):** Sau mỗi phép tích chập, dữ liệu thường được đưa qua hàm kích hoạt, phổ biến nhất là Rectified Linear Unit (ReLU): $f(x) = \max(0, x)$.
 - **Ý nghĩa:** Giúp mạng học được các mối quan hệ phức tạp, phi tuyến tính của dữ liệu, đồng thời giảm chi phí tính toán và khắc phục hiện tượng triệt tiêu đạo hàm (vanishing gradient).
3. **Lớp Gộp (Pooling Layer):** Thường được đặt sau lớp tích chập để giảm kích thước không gian của dữ liệu. Các kỹ thuật phổ biến là Max Pooling (lấy giá trị lớn nhất) hoặc Average Pooling (lấy giá trị trung bình).
 - **Ý nghĩa:** Giúp giảm số lượng tham số tính toán, đồng thời tạo ra tính bất biến (invariance) đối với các phép dịch chuyển nhỏ của đối tượng trong ảnh.

CNN có khả năng xử lý các đặc trưng ảnh tốt do trong ảnh, các pixel lân cận thường có mối liên hệ mật thiết với nhau và CNN có thể tận dụng được cấu trúc không gian (Spatial Structure) của dữ liệu. Do đó CNN nắm bắt tốt các "mẫu hình"(patterns) của ảnh. Đồ án tận dụng ưu điểm này để hướng đến mục tiêu nắm bắt các "mẫu hình"(patterns) tấn công mạng phức tạp mà các mô hình truyền thống bỏ sót.

2.3 Few-shot Learning

2.3.1 Bối cảnh và Động lực

Sự thành công rực rỡ của học sâu (Deep Learning) truyền thống phụ thuộc lớn vào sự sẵn có của các tập dữ liệu được dán nhãn khổng lồ. Tuy nhiên, trong nhiều lĩnh vực thực tế như y sinh, tài chính hay an ninh mạng, việc thu thập một lượng lớn mẫu dữ liệu là vô cùng khó khăn và tốn kém.

Đặc biệt trong bài toán phát hiện xâm nhập mạng (NIDS) với bộ dữ liệu tiêu chuẩn như NSL-KDD, sự mất cân bằng dữ liệu diễn ra rất nghiêm trọng. Trong khi các lưu lượng bình thường (Normal) hoặc tấn công phổ biến (như DoS, Probe) chiếm đa số, thì các hình thức tấn công tinh vi như chiếm quyền điều khiển (U2R) hay tấn công từ xa (R2L) lại có số lượng mẫu cực kỳ ít. Các mô hình học sâu thông thường khi huấn luyện trên các tập dữ liệu này thường có xu hướng "bỏ qua" các lớp thiểu số, dẫn đến tỷ lệ phát hiện sai (False Negative) rất cao.

Học ít mẫu (Few-shot Learning - FSL) ra đời nhằm thu hẹp khoảng cách giữa trí tuệ nhân tạo và trí tuệ con người — vốn có khả năng nhận diện một khái niệm mới chỉ sau một vài lần tiếp xúc. FSL cung cấp một khung làm việc cho phép mô hình học cách tổng quát hóa từ một số lượng rất hạn chế các mẫu được gán nhãn.


FSL không chỉ giúp giảm chi phí chuẩn bị dữ liệu mà còn nâng cao khả năng thích nghi của hệ thống an ninh trước các biến thể tấn công mới.

2.3.2 Định nghĩa bài toán N-way K-shot

Trong FSL, bài toán phân loại thường được thiết lập dưới dạng cấu trúc **N-way K-shot**. Đây là tiêu chuẩn để đánh giá khả năng thích nghi nhanh của mô hình:

- **N-way:** Đại diện cho số lượng lớp (loại tấn công) khác nhau mà mô hình cần phân loại trong một nhiệm vụ cụ thể.
- **K-shot:** Đại diện cho số lượng mẫu gán nhãn tương ứng với mỗi lớp để làm dữ liệu tham chiếu. Thông thường K là một số rất nhỏ. Ví dụ: 5-way 10-shot: Mô hình phải phân loại dữ liệu vào 5 loại tấn công khác nhau, trong đó mỗi loại chỉ được cung cấp 10 mẫu làm căn cứ.

2.3.3 Cơ chế Episode-based Training



Hình 2: Cách mô hình phân loại ảnh thuộc tập Query dựa trên tập Support

Khác với quy trình huấn luyện truyền thống, FSL sử dụng cơ chế huấn luyện theo tập (*Episode-based training*). Mục tiêu không phải là ghi nhớ dữ liệu, mà là "học cách học" (*Meta-learning*) để so khớp các đặc trưng.

Trong khung làm việc này, toàn bộ dữ liệu được tổ chức thành các tập như sau:

- **Meta-Training Set (Tập huấn luyện Meta):** Đây là tập dữ liệu lớn chứa các lớp cơ sở (*Base classes*) với số lượng mẫu dồi dào. Trong giai đoạn huấn luyện, mô hình sẽ tạo hàng nghìn episodes được lấy mẫu ngẫu nhiên từ tập Training này để học cách trích xuất đặc trưng và đo lường sự tương đồng giữa các mẫu.
- **Support Set (Tập hỗ trợ) $\mathcal{S}$:** Được trích xuất từ mỗi episode, chứa $N \times K$ mẫu dữ liệu đã dán nhãn. Đây là nguồn tri thức duy nhất để mô hình tham chiếu và hình thành các "nguyên mẫu"(prototypes) đặc trưng cho từng lớp trong không gian nhúng.
- **Query Set (Tập truy vấn) $\mathcal{Q}$:** Đóng vai trò là "bài kiểm tra", chứa các mẫu dữ liệu mới (chưa dán nhãn) thuộc N lớp trong tập $\mathcal{S}$. Mô hình phải dựa vào tri thức từ tập hỗ trợ để dự đoán nhãn cho các mẫu trong tập này.

Việc huấn luyện dựa trên episode giúp mô hình không chỉ học đặc trưng của từng lớp cụ thể mà còn học được chiến lược phân loại hiệu quả ngay cả khi đối tượng cần nhận diện chỉ có rất ít thông tin hỗ trợ.

2.3.4 Phân loại Few-shot Learning

Dựa trên sự phát triển của các nghiên cứu về Meta-learning và các phương pháp học truyền thống, Few-shot Learning thường được chia thành các nhóm tiếp cận chính sau:

1. **Hướng tiếp cận không dựa trên Meta-learning (Non-meta Learning):** Đây là cách tiếp cận dựa trên việc sử dụng các mô hình học sâu truyền thống được huấn luyện trên tập dữ liệu lớn, sau đó thực hiện tinh chỉnh (*Fine-tuning*) trên tập dữ liệu ít mẫu (*Support set*).
 - Cơ chế: Mô hình tận dụng tri thức đã học (Transfer Learning) để điều chỉnh các trọng số ở các tầng cuối cùng nhằm thích nghi với lớp mới.
 - Hạn chế: Trong bối cảnh Few-shot, phương pháp này dễ gặp hiện tượng (*Overfitting*) nghiêm trọng do số lượng mẫu mới quá ít không đủ để cập nhật tham số mạng một cách hiệu quả. Ngoài ra, nó không học được "cách tổng quát hóa" giữa các nhiệm vụ khác nhau.
2. **Hướng tiếp cận dựa trên tối ưu hóa (Optimization-based Meta-learning):** Tập trung vào việc tìm kiếm một bộ tham số khởi tạo tối ưu hoặc một chiến lược cập nhật Gradient sao cho mô hình có thể đạt đến điểm hội tụ chỉ sau một hoặc vài bước cập nhật với dữ liệu ít mẫu. Thuật toán tiêu biểu là MAML.
3. **Hướng tiếp cận dựa trên mô hình (Model-based Meta-learning):** Thiết kế các kiến trúc đặc biệt như mạng nơ-ron có bộ nhớ (*Memory-augmented*) hoặc mạng có cơ chế chú ý (*Attention*) để lưu trữ thông tin của các mẫu ít ỏi một cách nhanh chóng và sử dụng chúng để dự đoán cho mẫu mới.
4. **Hướng tiếp cận dựa trên độ đo (Metric-based Meta-learning):**

Đây là hướng tiếp cận phổ biến nhất cho FSL, có tính ổn định cao và ít phức tạp hơn về mặt tính toán so với hai nhóm Meta-learning còn lại và cũng là trọng tâm của đề tài này.

Thay vì cố gắng học một hàm phân loại trực tiếp (như Softmax trong CNN thường) để trả về xác suất từng lớp, Metric-based Meta Learning tập trung vào việc học một không gian nhúng (Embedding Space).

Trong không gian này, các mẫu thuộc cùng một lớp sẽ được kéo lại gần nhau, trong khi các mẫu khác lớp sẽ bị đẩy ra xa. Để xây dựng không gian nhúng tối ưu, Metric Learning thường sử dụng các độ đo và hàm mất mát:

- **Khoảng cách Euclidean:** Đo lường khoảng cách đường thẳng giữa hai điểm trong không gian đa chiều. Đây là độ đo chính được sử dụng trong mạng Prototypical Networks (sẽ trình bày ở Chương 3). Đối với hai vector u và v , khoảng cách được tính theo công thức:

$$d(u, v) = \sqrt{\sum_{i=1}^n (u_i - v_i)^2} \quad (2.2)$$

- **Độ tương đồng Cosine (Cosine Similarity):** Độ tương đồng Cosine đo góc giữa hai vector đặc trưng, tập trung vào "hướng" của hành vi thay vì độ lớn. Công thức tính như sau:


$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} \quad (2.3)$$

Trong đó:

- $\mathbf{A}$ và $\mathbf{B}$: Là hai vector đặc trưng (feature vectors) trong không gian nhúng n chiều.
- $\mathbf{A} \cdot \mathbf{B}$: Là tích vô hướng (*dot product*) của hai vector.
- $\|\mathbf{A}\|$ và $\|\mathbf{B}\|$: Là độ dài (chuẩn L_2) của từng vector.
- **Hàm mất mát - Triplet Loss:** Đây là kỹ thuật giúp mô hình học cách so sánh. Một bộ ba bao gồm:
 - **Anchor (A):** Mẫu gốc.
 - **Positive (P):** Mẫu cùng lớp với Anchor.
 - **Negative (N):** Mẫu khác lớp với Anchor.

Mục tiêu của hàm loss là tối thiểu hóa khoảng cách $d(A, P)$ và tối đa hóa khoảng cách $d(A, N)$ với một biên độ (margin) α nhất định:

$$L = \max(0, d(A, P)^2 - d(A, N)^2 + \alpha) \quad (2.4)$$



Hình 3: Sơ đồ phân loại Few-shot Learning

Chương 3

Phương pháp và kỹ thuật đề xuất

3.1 Tổng quan mô hình đề xuất

Để giải quyết các thách thức về sự mất cân bằng dữ liệu nghiêm trọng và đặc thù dữ liệu dạng bảng của bài toán phát hiện xâm nhập mạng (NIDS), đồ án đề xuất một khung làm việc (framework) tích hợp, chuyển đổi từ dữ liệu thô sang không gian hình ảnh và áp dụng kỹ thuật học sâu tiên tiến.

3.1.1 Kiến trúc hệ thống

Kiến trúc tổng thể của hệ thống được thiết kế theo mô hình xử lý tuần tự (Sequential Pipeline), bao gồm ba module chức năng chính hoạt động liên kết chặt chẽ với nhau:

1. **Module Chuyển đổi dữ liệu (Data Transformation):** Chịu trách nhiệm tiền xử lý và chuyển đổi dữ liệu mạng dạng bảng sang dạng hình ảnh sử dụng thuật toán IGTD.
2. **Module Trích xuất đặc trưng (Feature Extraction):** Đóng vai trò là mạng xương sống (Backbone) để học các đặc trưng không gian từ hình ảnh. Module này sử dụng mạng DSC-CNN.
3. **Module Phân loại và Huấn luyện (Classification & Training):** Thực hiện huấn luyện mô hình theo chiến lược lai ghép (Hybrid) và phân loại tấn công dựa trên độ đo, kết hợp các hàm mất Triplet Loss và Focal Loss trong cơ chế Few-shot.

3.2 Thuật toán IGTD

Mạng thần kinh tích chập (CNN) vốn được thiết kế để khai thác các phụ thuộc không gian hoặc thời gian trong dữ liệu tự nhiên như hình ảnh hoặc âm thanh. Tuy nhiên, dữ liệu dạng bảng thường thiếu các mối quan hệ không gian này. Thuật toán IGTD - Image Generator for Tabular Data được đề xuất nhằm chuyển đổi dữ liệu dạng bảng thành hình ảnh bằng cách gán các đặc trưng (features) vào các vị trí pixel sao cho các đặc trưng có độ tương đồng cao sẽ nằm gần nhau trong không gian 2D.

3.2.1 Khung lý thuyết và Xây dựng ma trận xếp hạng

Quá trình chuyển đổi dựa trên việc tối thiểu hóa sự khác biệt giữa cấu trúc quan hệ của các đặc trưng trong không gian gốc và cấu trúc khoảng cách của các pixel trong hình ảnh.

1. **Ma trận xếp hạng khoảng cách đặc trưng (R):**

- Giả sử dữ liệu bảng $\mathbf{X}$ có M mẫu và N đặc trưng.
- Tính toán khoảng cách cặp giữa các đặc trưng dựa trên một độ đo phù hợp (ví dụ: dùng khoảng cách Euclidean, $1 - \rho$ với ρ là hệ số tương quan,...).
- Các khoảng cách này được xếp hạng theo thứ tự tăng dần để tạo thành ma trận đối xứng $\mathbf{R}$ kích thước $N \times N$, trong đó $r_{i,j}$ là thứ hạng khoảng cách giữa đặc trưng i và đặc trưng j .

2. Ma trận xếp hạng khoảng cách pixel ($\mathbf{Q}$):

- Xác định lưới hình ảnh mục tiêu có kích thước $N_r \times N_c = N$.
- Tính toán khoảng cách giữa các cặp pixel dựa trên tọa độ của chúng trong lưới 2D.
- Các khoảng cách pixel được xếp hạng để tạo thành ma trận $\mathbf{Q}$ kích thước $N \times N$, với $q_{i,j}$ là thứ hạng khoảng cách giữa pixel i và pixel j .

3.2.2 Tối ưu hóa hàm mục tiêu - Objective Function

Mục tiêu của IGTD là tìm một phép gán các đặc trưng vào vị trí pixel sao cho ma trận $\mathbf{R}$ tương đồng nhất với ma trận $\mathbf{Q}$. Hàm lỗi được xác định như sau:

$$err(\mathbf{R}, \mathbf{Q}) = \sum_{i=2}^N \sum_{j=1}^{i-1} diff(r_{i,j}, q_{i,j}) \quad (3.1)$$

Trong đó, hàm $diff(\cdot)$ đo lường sự khác biệt giữa các thứ hạng, thường sử dụng giá trị tuyệt đối $|r_{i,j} - q_{i,j}|$ hoặc bình phương hiệu $(r_{i,j} - q_{i,j})^2$.

3.2.3 Quy trình thực thi thuật toán IGTD

Thuật toán sử dụng cơ chế hoán đổi lặp để giảm dần giá trị hàm lỗi thông qua 4 bước chính:

- **Bước 1: Khởi tạo:** Thiết lập chỉ số vòng lặp $s = 0$, tính lỗi ban đầu e_0 , và khởi tạo vectơ h để theo dõi lịch sử hoán đổi của từng đặc trưng.
- **Bước 2: Tìm kiếm đặc trưng hoán đổi:**
 - Xác định đặc trưng n^* lâu nhất chưa được xem xét hoán đổi (dựa trên giá trị nhỏ nhất trong h).
 - Tìm kiếm một đặc trưng l^* khác sao cho khi hoán đổi vị trí giữa n^* và l^* , giá trị lỗi $err(\mathbf{R}, \mathbf{Q})$ giảm đi một lượng lớn nhất.
- **Bước 3: Thực hiện hoán đổi có điều kiện:**
 - Nếu tỷ lệ giảm lỗi vượt qua một ngưỡng t_{swap} , thực hiện hoán đổi vị trí của n^* và l^* , cập nhật ma trận $\mathbf{R}$, giá trị lỗi mới và ghi nhận thời điểm hoán đổi vào h cho cả n^* và l^* .
 - Nếu không thỏa mãn, chỉ cập nhật thời điểm xem xét đặc trưng n^* vào h .
- **Bước 4: Kiểm tra hội tụ:** Thuật toán kết thúc khi đạt số vòng lặp tối đa S_{max} hoặc tỷ lệ giảm lỗi duy trì dưới ngưỡng t_{con} trong S_{con} vòng lặp liên tiếp.

Kết quả đầu ra: Sau khi tối ưu hóa, thuật toán trả về các chỉ số sắp xếp đặc trưng đã được tối ưu (k_{v^*}). Mỗi mẫu dữ liệu trong bảng ban đầu sẽ được chuyển đổi thành một hình ảnh $N_r \times N_c$, trong đó cường độ pixel tại mỗi vị trí phản ánh giá trị của đặc trưng tương ứng được gán cho vị trí đó.


3.3 Kiến trúc mạng nơ-ron tích chập khối DSC - CNN

3.3.1 Mạng nơ-ron tích chập tiêu chuẩn (Standard CNN)

Mạng nơ-ron tích chập tiêu chuẩn (CNN) là nền tảng của các mô hình thị giác máy tính, dựa trên cơ chế học các đặc trưng từ thấp đến cao thông qua các tầng phân cấp.

- **Nguyên lý vận hành:** Tích chập tiêu chuẩn thực hiện việc lọc (filtering) thông tin không gian (spatial) và thông tin kênh (channel) trong một bước duy nhất. Giả sử đầu vào là một khối dữ liệu có kích thước $D_F \times D_F \times M$ (với M là số kênh), hạt nhân tích chập sẽ có kích thước $D_K \times D_K \times M \times N$ (với N là số bộ lọc đầu ra).
- **Cơ chế học đặc trưng:** Các tầng dưới của CNN phát hiện các đặc trưng cục bộ cấp thấp như các cạnh, sau đó kết hợp chúng thành các đặc trưng trừu tượng cấp cao hơn để nhận diện đối tượng.
- **Chi phí tính toán:** Tổng chi phí tính toán cho một lớp tiêu chuẩn được xác định bởi công thức:

$$Cost_{std} = D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F \quad (3.2)$$




Hình 4: Standard Convolution Filters

3.3.2 Tích chập tách rời theo chiều sâu (Depthwise Separable Convolution - DSC)


Trong các hệ thống phân tán và thiết bị biên, việc giảm thiểu độ phức tạp tính toán là yêu cầu tiên quyết. Tích chập tách rời chiều sâu (DSC), được giới thiệu rộng rãi qua kiến trúc MobileNet, là một cải tiến giúp giảm đáng kể số lượng tham số và khối lượng tính toán.

- **Nguyên lý vận hành:** DSC chia phép tích chập truyền thống thành hai giai đoạn nhằm tối ưu hóa hiệu năng:
 1. **Depthwise Convolution:** Thay vì sử dụng hạt nhân dày quét qua toàn bộ kênh, bước này áp dụng một bộ lọc duy nhất cho mỗi kênh đầu vào có kích thước $D_K \times D_K \times 1$. Nhiệm vụ duy nhất ở đây là trích xuất các đặc trưng không gian của từng kênh riêng biệt.



Hình 5: Depthwise Convolution Filters

2. **Pointwise Convolution:** Để kết hợp thông tin giữa các kênh, một phép tích chập $1 \times 1 \times M \times N$ được áp dụng sau bước Depthwise. Bước này chịu trách nhiệm tạo ra sự kết hợp tuyến tính giữa các kênh để xây dựng các đặc trưng mới.



Hình 6: Pointwise Convolution

- **Chi phí tính toán:** Tổng chi phí cho DSC được tính theo công thức:

$$Cost_{dsc} = D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F \quad (3.3)$$

3.3.3 So sánh Standard CNN và DSC-CNN

- **Giảm tài nguyên tính toán:** Việc chuyển dịch từ Standard CNN sang DSC-CNN mang lại sự tinh giảm đáng kể về độ phức tạp tính toán. Tỷ lệ tiết kiệm tài nguyên được tính bằng công thức:

$$\frac{Cost_{dsc}}{Cost_{std}} = \frac{D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F}{D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad (3.4)$$

- **Hiệu quả tài nguyên:** Với hạt nhân 3×3 , DSC giúp giảm khối lượng tính toán và số lượng tham số xuống khoảng 8 đến 9 lần so với tích chập tiêu chuẩn. Điều này giúp tránh các lỗi tràn bộ nhớ (out-of-memory) thường gặp khi huấn luyện các mô hình lớn.
- **Tối ưu hóa cho Federated Learning:** Trong môi trường FL, việc giảm số lượng tham số giúp giảm đáng kể băng thông truyền tải giữa các nút (clients) và máy chủ trung tâm, đồng thời tăng tốc độ huấn luyện cục bộ tại các thiết bị biên có cấu hình yếu.

3.4 Chiến lược huấn luyện Lai (Hybrid Training)

Để khắc phục vấn đề mất cân bằng dữ liệu, đồ án áp dụng chiến lược huấn luyện hai giai đoạn, kết hợp giữa việc học biểu diễn chung và tinh chỉnh cho các lớp hiếm.

3.4.1 Giai đoạn 1: Pre-training với Triplet Loss

Sử dụng Triplet Loss để huấn luyện mạng backbone học không gian nhúng từ các lớp dữ liệu lớn.

$$L_{triplet} = \max(0, |f(x_a) - f(x_p)|^2 - |f(x_a) - f(x_n)|^2 + \alpha) \quad (3.5)$$

Mục tiêu là giảm khoảng cách giữa các mẫu cùng lớp (Anchor-Positive) và tăng khoảng cách giữa các mẫu khác lớp (Anchor-Negative).

3.4.2 Giai đoạn 2: Fine-tuning với Focal Loss

Trong giai đoạn Few-shot, sử dụng Focal Loss để tập trung vào các mẫu khó phân loại (Hard examples) như U2R:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (3.6)$$

Trong đó, γ làm giảm trọng số của các mẫu dễ, và α_t được thiết lập cao cho các lớp thiểu số để cân bằng sự đóng góp vào hàm mất mát tổng thể.

3.5 Lập luận lựa chọn phương pháp

3.5.1 Lý do lựa chọn Metric-based Few-shot Learning

Trong bối cảnh Few-shot Learning, nghiên cứu này ưu tiên hướng tiếp cận dựa trên độ đo (Metric-based) vì tính ổn định và hiệu quả tính toán vượt trội so với các phương pháp dựa trên tối ưu hóa như MAML:

- **Hiệu năng tính toán:** MAML đòi hỏi tính toán đạo hàm bậc hai (Hessian matrix), gây tốn kém tài nguyên và dễ dẫn đến hiện tượng bùng nổ hoặc triệt tiêu gradient. Ngược lại, Metric-based chỉ yêu cầu tính toán khoảng cách/độ tương đồng, phù hợp cho việc triển khai trên các hệ thống phát hiện xâm nhập thời gian thực.
- **Sự ổn định trong huấn luyện và khả năng tổng quát hóa:** Các phương pháp Metric-based học một không gian nhúng (embedding space) nơi các mẫu được so khớp dựa trên độ tương đồng giúp mô hình thích nghi nhanh với các lớp tấn công mới chỉ với rất ít mẫu gán nhãn.

3.5.2 Lý do lựa chọn IGTD kết hợp DSC-CNN

Trong các phương pháp Metric-based, các bộ trích xuất đặc trưng mạnh mẽ nhất trong không gian nhúng (embedding space) thường là các mạng nơ-ron tích chập (CNN). Tuy nhiên đặc thù của dữ liệu NSL-KDD là dạng bảng (tabular data), vốn không có quan hệ không gian tự nhiên giữa các đặc trưng, việc áp dụng trực tiếp CNN thường không mang lại hiệu quả cao. Do vậy, thuật toán IGTD là một phần không thể thiếu để chuyển đổi dữ liệu bảng thành hình ảnh, song:

- **Bảo toàn cấu trúc lân cận:** IGTD gán các đặc trưng vào các vị trí pixel sao cho các đặc trưng tương đồng sẽ nằm gần nhau thông qua việc tối thiểu hóa sự sai khác giữa xếp hạng khoảng cách đặc trưng và xếp hạng khoảng cách pixel.
- **Tính nhỏ gọn (Compactness):** Khác với các phương pháp chiều như DeepInsight thường tạo ra nhiều pixel trống, IGTD tạo ra đại diện hình ảnh mà mỗi pixel tương ứng với một đặc trưng duy nhất. Điều này giúp CNN khai thác tối đa mật độ thông tin trên hình ảnh.

Đồng thời, trong môi trường Federated Learning (FL) việc giảm kích thước mô hình là yếu tố then chốt để tiết kiệm băng thông truyền tải tham số. Do đó thay vì các kiến trúc CNN tiêu chuẩn thường tiêu tốn nhiều tài nguyên tính toán và bộ nhớ, việc lựa chọn mạng nơ-ron tích chập tách rời theo chiều sâu (DSC-CNN) mang lại nhiều lợi thế:

- **Hiệu quả tài nguyên:** DSC-CNN giảm đáng kể số lượng tham số và khối lượng tính toán (khoảng 8-9 lần) so với CNN tiêu chuẩn, giúp tránh các lỗi tràn bộ nhớ (out-of-memory) thường gặp khi huấn luyện mô hình trên thiết bị biên.

- **Tối ưu hóa bộ nhớ và tốc độ:** IGTD tạo ra các đại diện hình ảnh nhỏ gọn (compact), không có vùng trống. Khi kết hợp với DSC, mô hình đòi hỏi ít bộ nhớ hơn và cho tốc độ huấn luyện nhanh hơn đáng kể.
- **Giảm băng thông:** Trong khung làm việc FL, số lượng tham số ít hơn của DSC giúp giảm đáng kể lượng dữ liệu cần truyền tải giữa máy chủ trung tâm và các nút cục bộ.

3.5.3 Lý do lựa chọn độ đo Metric-based: Khoảng cách Euclidean

Với hướng tiếp cận dựa trên độ đo (Metric-based), đề tài lựa chọn Euclidean Distance với các ưu điểm sau:

- **Cơ sở lý thuyết vững chắc:** Prototypical Networks hoạt động dựa trên giả định rằng các điểm dữ liệu của một lớp sẽ phân bố xung quanh một nguyên mẫu (prototype) trung tâm theo phân phối thuộc họ hàm mũ (Exponential Family Densities). Trong trường hợp này, khoảng cách Euclid bình phương tương ứng với việc tối đa hóa hàm log-likelihood của phân phối Gaussian, là mô hình tự nhiên nhất cho việc phân cụm trong không gian nhúng.
- **Tính đơn giản và hiệu quả tính toán:** Khoảng cách Euclid ($d(x, y) = \|x - y\|_2$) có chi phí tính toán thấp hơn so với Cosine (vốn cần tính tích vô hướng và chuẩn hóa vector). Điều này đặc biệt quan trọng khi phải tính toán khoảng cách bắt cặp (pairwise distance) liên tục giữa tập Query và Support trong mỗi Episode huấn luyện.
- **Thực nghiệm trên không gian IGTD:** Dữ liệu sau khi qua IGTD và DSC-CNN đã được chuẩn hóa. Thực nghiệm cho thấy khoảng cách Euclid giúp phân tách các cụm dữ liệu (clusters) rõ ràng hơn trong không gian đặc trưng so với Cosine khi kết hợp với hàm kích hoạt ReLU (vốn tạo ra các vector đặc trưng không âm và thừa).

Chương 4

Xây dựng mô hình và triển khai hệ thống

4.1 Môi trường cài đặt

- **Phần cứng:** Máy ảo Kaggle, GPU NVIDIA Tesla T4 (16GB VRAM) để tăng tốc huấn luyện mạng tích chập và tính toán khoảng cách trong không gian nhúng.
- **Ngôn ngữ lập trình:** Python 3.12.12
- **Thư viện chính:**
 - PyTorch: Thư viện lõi để xây dựng kiến trúc mạng DSC-CNN, định nghĩa các hàm mất mát (Triplet, Focal Loss) và tối ưu hóa tham số.
 - Scikit-learn: Tiềm xử lý dữ liệu và tính toán chỉ số đánh giá
 - Scipy: Hỗ trợ tính toán khoảng cách đặc trưng trong thuật toán IGTD
 - Pandas & NumPy: Sử dụng để thao tác với dữ liệu bảng (DataFrame) và xử lý mảng đa chiều.
 - Matplotlib & Seaborn: Trực quan hóa

4.2 Tiềm xử lý dữ liệu

Quy trình này được thiết kế để chuẩn hóa dữ liệu bảng về dạng ma trận số phù hợp cho thuật toán IGTD và đảm bảo tính hội tụ của mô hình.

4.2.1 Ánh xạ nhóm- nhãn tấn công

Dữ liệu gốc NSL-KDD chứa 39 nhãn tấn công chi tiết. Để phù hợp với bài toán phân loại 5 lớp (5-way) trong mô hình Few-shot, hệ thống thực hiện ánh xạ về 5 nhóm chính:

- Normal: normal.
- DoS: back, land, neptune, pod, smurf, teardrop, mailbomb, processtable, udpstorm, apache2, worm.
- Probe: satan, ipsweep, nmap, portsweep, mscan, saint.
- R2L: ftp_write, guess_passwd, imap, multihop, phf, spy, warezclient, warezmaster, snmpgetattack, httpunnel, snmpguess, sendmail, named, xlock, xsnoop.
- U2R: buffer_overflow, loadmodule, perl, rootkit, ps, sqlattack, xterm.


4.2.2 Xử lý đặc trưng

1. **Lọc dữ liệu:** Kiểm tra và loại bỏ các giá trị nhiễu, dư thừa trong tập dữ liệu để đảm bảo tính toán ma trận khoảng cách chính xác.
 - Loại bỏ đặc trưng `num_outbound_cmds` (do chỉ chứa giá trị 0) và cột `difficulty_level`.
2. **Mã hóa nhãn đặc trưng:** Các đặc trưng định danh (categorical) được chuyển đổi sang dạng số nguyên bằng `LabelEncoder`:
 - `protocol_type`: $\{tcp, udp, icmp\} \rightarrow \{0, 1, 2\}$.
 - `service`: $\{http, smtp, ftp, \dots\} \rightarrow \{0, 1, \dots, 69\}$.
 - `flag`: $\{SF, SO, REJ, \dots\} \rightarrow \{0, 1, \dots, 10\}$.
3. **Chuẩn hóa:** Sử dụng `QuantileTransformer` với `output_distribution='uniform'`. Phương pháp này giúp làm mịn phân phối, giảm ảnh hưởng của nhiễu và làm nổi bật các sai biệt nhỏ của các lớp hiếm (U2R, R2L) trong không gian đặc trưng.

4.2.3 Cơ chế IGTD

Dữ liệu sau khi chuẩn hóa sẽ được chuyển đổi từ dạng bảng (1D) sang dạng ảnh xám (2D):

- Input: 41 đặc trưng gốc $\rightarrow$ loại bỏ nhãn và đặc trưng nhiễu $\rightarrow$ còn lại 40 đặc trưng hữu ích.
- Padding: Để tạo thành ảnh vuông kích thước $7 \times 7 = 49$ pixel, cần thực hiện chèn thêm 9 đặc trưng giả với giá trị 0.
- Ma trận khoảng cách: Tính toán khoảng cách Pearson Correlation giữa các đặc trưng. Các đặc trưng có tương quan cao sẽ có khoảng cách nhỏ.
- Hàm thực thi: Sử dụng kỹ thuật tối ưu hóa hoán đổi (Swapping) để ánh xạ các đặc trưng vào lưới 7×7 sao cho các đặc trưng tương quan cao nằm cạnh nhau, bảo toàn cấu trúc khoảng cách tương quan trong không gian 2D.
- Output Image: Dữ liệu đầu ra là các tensor hình ảnh xám kích thước $(1, 7, 7)$, sẵn sàng đưa vào mạng CNN.



Hình 7: Minh họa mẫu tấn công sau khi qua IGTD

4.3 Xây dựng Kiến trúc mô hình

4.3.1 Khối tích chập tách rời DSC Block

Mô hình sử dụng khối cơ bản gồm các lớp theo thứ tự:

- Conv2d: Tích chập với kernel 3×3 , padding=1.

- BatchNorm2d: Chuẩn hóa batch để ổn định quá trình huấn luyện.
- ReLU: Hàm kích hoạt phi tuyến.
- MaxPool2d (tại Block 1) hoặc AdaptiveAvgPool2d (tại Block 2) để giảm chiều dữ liệu.

4.3.2 Kiến trúc mạng Backbone DSC_CNN

Mạng Backbone được thiết kế nhỏ gọn để phù hợp với ảnh đầu vào kích thước nhỏ (7×7):

- Input: $Batch \times 1 \times 7 \times 7$.
- Layer 1: DSC Block ($1 \rightarrow 64$ filters). Output size: $3 \times 3 \times 64$.
- Layer 2: DSC Block ($64 \rightarrow 128$ filters) + Global Average Pooling.
- Output Embedding: Vector đặc trưng 1 chiều kích thước 128.

4.4 Chiến lược huấn luyện lại

4.4.1 Giai đoạn 1: Pre-training (Học đại diện)

- Mục tiêu: Xây dựng không gian nhúng sử dụng các lớp dữ liệu phong phú (Normal, DoS, Probe).
- Loss Function: Triplet Loss với margin $\alpha = 1.0$, $p=2$ (Euclidean distance)
- Optimizer: Adam, Learning rate = $1e - 3$.

4.4.2 Giai đoạn 2: Few-shot Learning với Prototypical Networks

- Cấu hình Episode: 5-way 20-shot.
 - Support Set: 5 lớp $\times$ 20 mẫu/lớp = 100 mẫu.
 - Query Set: 5 lớp $\times$ 15 mẫu/lớp = 75 mẫu.
- Prototype: Trung bình cộng các vector nhúng của từng lớp trong Support Set
- Khoảng cách: Euclidean Distance (âm) được sử dụng để tính xác suất Log-Softmax. Việc phân loại mẫu mới dựa trên khoảng cách Euclidean đến các Prototype.

4.4.3 Tinh chỉnh Focal Loss

Để giải quyết sự mất cân bằng lớp cực đoan giữa U2R/R2L và Normal/DoS, hệ thống áp dụng Focal Loss với bộ trọng số α_t được tinh chỉnh thủ công:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (4.1)$$


- $\gamma = 2.0$.
- Trọng số α_t :
 - Normal: 1.0
 - DoS, Probe: 2.0
 - U2R: 40.0
 - R2L: 60.0

4.5 Kết quả và đánh giá

4.5.1 Bộ trích xuất đặc trưng



Hình 8: Vị trí của các đặc trưng lên lưới ảnh 7x7




Hình 9: Heatmap so sánh giá trị trung bình pixel giữa từng lớp Attack - Normal

- **Màu đỏ:** Tại vị trí pixel đó, giá trị của lớp Attack cao hơn so với lớp Normal. Đây là những đặc trưng "nổi trội" của cuộc tấn công
- **Màu xanh:** Tại vị trí pixel đó, giá trị của lớp Attack thấp hơn so với lớp Normal. Đây là những đặc trưng mà cuộc tấn công thường "ít thực hiện" hoặc có giá trị nhỏ hơn bình thường.

Nhận xét:

- Thuật toán IGTD đã gom nhóm thành công các đặc trưng có độ tương quan cao lại gần nhau, tạo thành các "vùng" pixel có cường độ sáng đặc trưng. Như vậy mỗi loại tấn công tạo ra một "họa tiết" ảnh đặc trưng.
- Sự khác biệt cấu trúc: Có sự khác biệt rõ rệt về phân bố cường độ sáng giữa nhóm Normal và nhóm Attack. Nhóm Attack thường có các điểm nóng tập trung ở các đặc trưng liên quan đến lưu lượng mạng bất thường.

Ý nghĩa: Cấu trúc không gian này tạo điều kiện thuận lợi cho mạng DSC-CNN sử dụng các bộ lọc tích chập để trích xuất biên dạng và đặc trưng cục bộ, điều mà các mô hình học máy truyền thống trên dữ liệu bảng không làm được.




Hình 10: Biểu diễn không gian đặc trưng (Embedding Space) 2 chiều của các lớp Attack và Normal

Biểu đồ t-SNE minh họa cách mô hình DSC-CNN ánh xạ các mẫu dữ liệu từ không gian đặc trưng ban đầu (40 chiều) sang không gian nhúng (128 chiều) và được giảm chiều xuống 2D để trực quan hóa. Từ hình ảnh phân bố, ta có những quan sát:

- Có sự tách biệt tương đối giữa các cụm màu đại diện cho 5 nhóm lớp (Normal, DoS, Probe, R2L, U2R). Điều này chứng minh hiệu quả của Triplet Loss trong giai đoạn Pre-training. Hàm mất mát này đã thành công trong việc đẩy các mẫu khác lớp ra xa nhau, tạo ra các ranh giới quyết định (decision boundaries) rõ nét giúp bộ phân loại hoạt động chính xác.
- Các điểm dữ liệu thuộc cùng một lớp (đặc biệt là Normal và DoS) có xu hướng tụ lại thành các cụm rất chặt chẽ. Điều này cho thấy mô hình đã học được các đặc trưng bất biến (invariant features) cốt lõi của từng loại tấn công, giảm thiểu sự phân tán không cần thiết gây nhiễu cho quá trình phân loại.

- Quan sát cụm R2L/U2L, ta thấy độ tập trung thấp hơn so với các lớp khác. Điều này phản ánh độ phức tạp cũng như sự đa dạng cao của các biến thể tấn công trong nhóm này.

4.5.2 Chỉ số đánh giá mô hình



Hình 11: Confusion Matrix

Ma trận nhầm lẫn (Confusion Matrix):

- **TP (True Positive):** Số mẫu tấn công được phân loại đúng là tấn công.
- **TN (True Negative):** Số mẫu bình thường được phân loại đúng là bình thường.
- **FP (False Positive):** Số mẫu bình thường bị nhận nhầm là tấn công (Báo động giả).
- **FN (False Negative):** Số mẫu tấn công bị nhận nhầm là bình thường (Bỏ lọt tấn công).

Các chỉ số đánh giá hiệu năng được tính toán như sau:

1. Accuracy (Độ chính xác toàn thể):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.2)$$

Ý nghĩa: Đo lường tỷ lệ phần trăm các dự đoán đúng trên tổng số các trường hợp. Tuy nhiên, đối với dữ liệu mất cân bằng như NSL-KDD, chỉ số này không phản ánh đủ được hiệu suất thực sự của mô hình.

2. Precision (Độ chuẩn):

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4.3)$$

Ý nghĩa: Cho biết trong số các mẫu được mô hình cảnh báo là tấn công, có bao nhiêu phần trăm là tấn công thực sự. Trong an ninh mạng, Precision cao đồng nghĩa với việc **tỷ lệ báo động giả (False Alarm Rate) thấp**, giúp giảm tải công việc cho người quản trị mạng.

3. Recall (Độ phủ / Độ nhạy):

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4.4)$$

Ý nghĩa: Cho biết mô hình phát hiện được bao nhiêu phần trăm các cuộc tấn công thực tế. Đối với hệ thống IDS, Recall là chỉ số quan trọng nhất vì việc **bỏ lọt tấn công (False Negative)** thường gây hậu quả nghiêm trọng hơn nhiều so với báo động giả.

4. F1-Score:

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.5)$$

Ý nghĩa: Là trung bình điều hòa giữa Precision và Recall. F1-Score cung cấp một cái nhìn tổng quát hơn khi cần cân bằng giữa việc giảm thiểu báo động giả (Precision) và giảm thiểu bỏ lọt tấn công (Recall). Chỉ số này đặc biệt hữu ích để đánh giá hiệu năng trên các lớp hiếm (như U2R, R2L).


4.5.3 Kịch bản đánh giá

1. Kiểm tra khả năng học - ghi nhớ

- Support Set: KDDTrain+
- Query Set: KDDTrain+
- Kết quả:

Bảng 4.1: Kết quả đánh giá mô hình trên tập huấn luyện (KDDTrain+)

Lớp (Class)	Precision	Recall	F1-Score	Support
Normal	0.9492	0.8917	0.9195	75,000
DoS	0.9934	0.9866	0.9900	75,000
Probe	0.9808	0.9801	0.9805	75,000
R2L	0.9279	0.9579	0.9427	75,000
U2R	0.9568	0.9910	0.9736	75,000
Accuracy			0.9615	375,000
Macro Avg	0.9616	0.9615	0.9613	375,000
Weighted Avg	0.9616	0.9615	0.9613	375,000



Hình 12: Confusion Matrix với KDDTrain+


- Nhận xét:
 - Mô hình đạt độ chính xác tổng thể rất cao (96.15%).
 - Các chỉ số F1-Score của cả 5 lớp đều vượt qua mức 0.90. Đặc biệt, lớp khó nhất là U2R đạt Recall lên tới 99.10%.
 - Kết luận: Mô hình có khả năng hội tụ tốt, đủ năng lực để ghi nhớ các đặc trưng phức tạp của dữ liệu huấn luyện mà không gặp hiện tượng underfitting.

2. Kiểm tra khả năng khả năng tổng quát hóa

- Support Set: KDDTrain+
- Query Set: KDDTest+
- Kết quả:

Bảng 4.2: Kết quả đánh giá mô hình trên tập kiểm thử (KDDTest+)

Lớp (Class)	Precision	Recall	F1-Score	Support
Normal	0.4649	0.9247	0.6187	75,000
DoS	0.8648	0.7534	0.8053	75,000
Probe	0.8881	0.7843	0.8330	75,000
R2L	0.6554	0.3166	0.4270	75,000
U2R	0.9334	0.7219	0.8141	75,000
Accuracy				0.7002
Macro Avg	0.7613	0.7002	0.6996	375,000
Weighted Avg	0.7613	0.7002	0.6996	375,000



Hình 13: Confusion Matrix với KDDTest+


- Nhận xét:
 - Độ chính xác giảm xuống 70.02%, phản ánh sự khác biệt về phân phối dữ liệu thực tế so với tập huấn luyện.
 - Điểm sáng: Lớp U2R duy trì được F1-Score ấn tượng (0.8141) với Recall 72.19%. Đây là kết quả vượt trội so với các nghiên cứu sử dụng CNN truyền thống (thường chỉ đạt dưới 50% cho U2R)
 - Hạn chế: Lớp R2L có kết quả thấp nhất (F1 0.42). Nguyên nhân là do tập Test+ chứa nhiều biến thể tấn công R2L mới (Zero-day attacks) có hành vi khác hẳn so với tập Train, khiến mô hình gặp khó khăn trong việc suy luận.

3. Kiểm tra độ bền vững trên mẫu khó

- Support Set: KDDTrain+
- Query Set: KDDTest-21
- Kết quả:

Bảng 4.3: Kết quả đánh giá chi tiết trên tập kiểm thử khó (KDDTest-21)

Lớp (Class)	Precision	Recall	F1-Score	Support
Normal	0.3914	0.7726	0.5196	75,000
DoS	0.8143	0.5904	0.6845	75,000
Probe	0.8017	0.7833	0.7924	75,000
R2L	0.5853	0.3173	0.4115	75,000
U2R	0.9196	0.7191	0.8071	75,000
Accuracy				0.6365
Macro Avg	0.7025	0.6365	0.6430	375,000
Weighted Avg	0.7025	0.6365	0.6430	375,000



Hình 14: Confusion Matrix với KDDTest-21

- Nhận xét:
 - Khi loại bỏ các mẫu dễ đoán (tập Test-21), độ chính xác tổng thể giảm còn 63.65%
 - Tuy nhiên, hiệu năng trên lớp U2R vẫn rất ổn định (F1 0.80). Điều này chứng minh rằng mô hình thực sự học được các đặc trưng cốt lõi của tấn công leo thang đặc quyền.

4. Đánh giá sự ổn định

Bảng 4.4: Kết quả trung bình và độ lệch chuẩn trên 5 seed ngẫu nhiên (Tập KDDTest+)

Chỉ số (Metric)	Kết quả (Mean $\pm$ Std)
Accuracy	0.6653 $\pm$ 0.0190
Normal Recall	0.9169 $\pm$ 0.0074
DoS Recall	0.7193 $\pm$ 0.0512
Probe Recall	0.7298 $\pm$ 0.1004
R2L Recall	0.3501 $\pm$ 0.0795
U2R Recall	0.6105 $\pm$ 0.0676

• Nhận xét:

- Độ lệch chuẩn (Std) của lớp Normal rất nhỏ (± 0.0074), cho thấy sự ổn định tuyệt đối trong việc nhận diện lưu lượng bình thường.
- Kết quả Recall trung bình của lớp U2R đạt 61.05% với độ lệch chuẩn ± 0.0676 , cao hơn đáng kể so với các phương pháp truyền thống (thường gần 0% hoặc <20% đối với U2R)
- Lớp Probe có độ lệch chuẩn cao nhất (± 0.1004). Điều này cho thấy hiệu năng phát hiện hành vi do thám phụ thuộc khá nhiều vào chất lượng của tập Support Set được lấy mẫu ngẫu nhiên trong mỗi lần chạy
- Kết luận chung: Độ chính xác tổng thể biến động trong khoảng nhỏ ($\pm 1.9\%$), cho thấy hệ thống có tính ổn định tốt, khẳng định tính khả thi của mô hình trong môi trường dữ liệu luôn biến đổi.

Chương 5

Tổng kết và Tiềm năng tích hợp Federated Learning

5.1 Tổng kết kết quả nghiên cứu

Đồ án đã tập trung giải quyết một trong những thách thức lớn nhất của các hệ thống phát hiện xâm nhập mạng (NIDS) hiện nay: Sự mất cân bằng dữ liệu nghiêm trọng và khả năng phát hiện các cuộc tấn công hiếm gặp. Thông qua việc đề xuất và triển khai một quy trình tích hợp gồm ba thành phần chính: chuyển đổi dữ liệu IGTD, trích xuất đặc trưng DSC-CNN và chiến lược huấn luyện Few-shot Learning với Focal Loss, nghiên cứu đã đạt được các kết quả đáng ghi nhận:

1. **Hiệu quả trên lớp tấn công hiếm (Minority Classes):** Mô hình đã khắc phục được điểm yếu cố hữu của các phương pháp học máy truyền thống đối với lớp tấn công leo thang đặc quyền (U2R). Kết quả thực nghiệm cho thấy Recall của U2R đạt mức 72.19% trên tập kiểm thử và duy trì độ ổn định qua nhiều lần chạy (độ lệch chuẩn thấp). Điều này chứng minh rằng việc kết hợp mạng nguyên mẫu (Prototypical Networks) và hàm mất mát Focal Loss là một chiến lược đúng đắn để định hướng mô hình tập trung vào các mẫu khó.
2. **Tối ưu hóa tài nguyên tính toán:** Việc áp dụng kiến trúc tích chập tách biệt chiều sâu (DSC-CNN) trên dữ liệu hình ảnh IGTD (kích thước nhỏ 7×7) giúp mô hình có số lượng tham số cực thấp so với các mạng CNN tiêu chuẩn. Điều này mở ra khả năng triển khai hệ thống trên các thiết bị biên hoặc các nút mạng có tài nguyên hạn chế.
3. **Khả năng biểu diễn dữ liệu:** Thuật toán IGTD đã chứng minh khả năng chuyển đổi dữ liệu bảng thành hình ảnh mà vẫn bảo toàn được các mối quan hệ tương quan giữa các đặc trưng, giúp các bộ lọc tích chập hoạt động hiệu quả trong việc trích xuất đặc trưng không gian.

5.2 Hạn chế tồn tại

Bên cạnh những ưu điểm, nghiên cứu vẫn còn một số hạn chế cần khắc phục trong tương lai:

- **Khả năng tổng quát hóa trên lớp R2L:** Hiệu năng phát hiện tấn công R2L trên tập kiểm thử còn thấp (Recall $\sim 35\%$). Nguyên nhân chủ yếu do sự thay đổi phân phối dữ liệu (Concept Drift) giữa tập huấn luyện và kiểm thử là quá lớn, khiến khoảng cách Metric Learning học được chưa đủ bao quát các biến thể tấn công mới.

- **Tỷ lệ báo động giả (False Positive):** Precision của lớp Normal chưa cao ($\sim 46\%$), đồng nghĩa với việc nhiều lưu lượng bình thường bị nhận nhầm là tấn công, gây ra các cảnh báo nhiễu cho người quản trị.

5.3 Tiềm năng tích hợp Federated Learning

Dựa trên kiến trúc DSC-CNN gọn nhẹ đã xây dựng, hướng phát triển tiếp theo của đồ án là tích hợp mô hình này vào khung làm việc Học liên kết (Federated Learning - FL). Đây là xu hướng tất yếu của an ninh mạng hiện đại vì những lý do sau:

5.3.1 Sự phù hợp của DSC-CNN với môi trường biên

Trong mô hình FL, quá trình huấn luyện diễn ra cục bộ tại các thiết bị người dùng (Client) hoặc các Gateway, sau đó chỉ gửi trọng số (Weights) về Server trung tâm để tổng hợp.

- Kiến trúc DSC-CNN được đề xuất trong đồ án này có ưu điểm là nhẹ và tốn ít tài nguyên tính toán. Điều này cực kỳ lý tưởng để chạy trên các router, switch hoặc thiết bị IoT mà không làm ảnh hưởng đến hiệu năng mạng chính.
- Kích thước ảnh IGTD nhỏ (7×7) giúp giảm thiểu chi phí tính toán cục bộ và băng thông truyền tải tham số.

5.3.2 Bảo mật quyền riêng tư dữ liệu

Dữ liệu lưu lượng mạng (Network Traffic) thường chứa các thông tin nhạy cảm của tổ chức hoặc cá nhân.

- Với cách tiếp cận tập trung hiện tại, dữ liệu phải được đưa về một máy chủ để huấn luyện, tạo ra rủi ro về rò rỉ dữ liệu.
- Khi tích hợp FL, dữ liệu thô (raw packet) và ảnh IGTD không bao giờ rời khỏi thiết bị cục bộ. Chỉ có các cập nhật tham số (gradients/weights) được chia sẻ, đảm bảo tính riêng tư (Privacy-preserving) cho hệ thống NIDS.

5.3.3 Kiến trúc đề xuất cho tương lai

Một hệ thống *Federated Few-shot Intrusion Detection System* có thể được triển khai theo quy trình:

1. **Global Model:** Máy chủ trung tâm duy trì một mô hình DSC-CNN toàn cục, học các đặc trưng tấn công phổ biến (như DoS, Probe).
2. **Local Adaptation:** Mỗi nút mạng (Client) sử dụng dữ liệu cục bộ của mình để tinh chỉnh mô hình. Nếu xuất hiện một dạng tấn công mới (ví dụ: biến thể Zero-day của R2L) tại một nút mạng cụ thể, cơ chế Few-shot Learning sẽ giúp nút mạng đó học nhanh chóng chỉ với vài mẫu.
3. **Aggregation:** Các tri thức mới về cuộc tấn công này (dưới dạng trọng số) được gửi về Server và cập nhật cho toàn bộ mạng lưới, giúp các nút khác cũng có khả năng phòng thủ mà không cần chia sẻ dữ liệu tấn công gốc.

5.4 Kết luận chung

Đồ án đã xây dựng thành công một quy trình phát hiện xâm nhập mạng hiệu quả, đặc biệt ưu việt trong việc phát hiện các tấn công hiếm gặp. Việc kết hợp giữa IGTD, DSC-CNN và Few-shot Learning không chỉ giải quyết bài toán hiện tại mà còn tạo ra một nền tảng kiến trúc vững chắc, sẵn sàng cho việc mở rộng sang môi trường phân tán và bảo mật cao như Federated Learning trong tương lai.

Tài liệu tham khảo

- [1] A. Parnami and M. Lee, “Learning from few examples: A summary of approaches to few-shot learning”, *arXiv preprint arXiv:2203.04291*, 2022.
- [2] Y. Zhu, T. Brettin, et al., “Converting tabular data into images for deep learning with convolutional neural networks”, *Scientific reports*, vol. 11, no. 1, pp. 1–11, 2021.
- [3] S. Wang, *Deep learning lecture notes and course materials*, <https://github.com/wangshusen/DeepLearning>, Accessed: 2024-05-20, 2020.
- [4] A. G. Howard et al., “Mobilenets: Efficient convolutional neural networks for mobile vision applications”, *arXiv preprint arXiv:1704.04861*, 2017.
- [5] GeeksforGeeks. “Depth-wise separable convolutional neural networks”, Accessed: May 20, 2024. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/depth-wise-separable-convolutional-neural-networks/>.